金融投诉文本的六类自动分流与人工复核系统

阶段二报告 | 数据与实验设计

项目	提交信息
课程 / 阶段	Python 与人工智能 / 阶段二
团队 / 成员	杨俊炜、赵煜凡
Git 仓库 URL / 提交标识	https://github.com/cwiapp/financial-complaint-routing phase-2-submission-v2（Git 标签）
日期	2026 年 11 月 4 日

执行摘要

本阶段将金融投诉文本分类限定为历史公开叙述中的六类产品分流。在工作簿对应的 1,048,575 条记录中，只有 17,093 条有叙述；六类共有 14,919 条。按标准化文本去重并先分组再按月份划分，训练、验证、测试集分别为 3,615、6,111、2,742 条。测试集上朴素贝叶斯宏平均 F1 为 0.717，与多数类和规则基线同集比较。主要局限是叙述选择偏差、标签噪声和历史数据时效；下一阶段将比较更强模型及错误成本。

1 修订问题与成功定义

决策任务：只根据首次受理时可获得的英文投诉叙述，建议六类产品路由；低置信或无效输入交人工复核。Product 是消费者选择的代理标签，不是经调查裁定的事实。系统不判断投诉真伪、违法性或赔偿。

阶段一反馈响应：截至本报告生成时未收到可核对的教师评语；本阶段按评分量规补齐数据字典、缺失与偏差分析、固定时间划分、防泄漏检查、可重跑基线及不确定性。若有正式反馈，须在下一次修订附录逐项回应。

成功标准：测试期宏平均 F1 为主指标；同时报告整体准确率、各类召回率与转人工覆盖率，避免多数类掩盖少数类。目标阈值沿用阶段一的探索性标准，不依据五月测试结果调整。

阶段一到阶段二的可核对变化

事项	阶段一	阶段二
数据使用	六月试运行片段	历史快照审计、跨月去重和固定三段划分
方法	多数类与固定规则	增加训练集拟合的词袋朴素贝叶斯
证据	单月原型检查	五月独立测试、类别召回率与 95% 区间

2 数据来源、观察单位与字典

来源为用户提供的 CFPB 投诉数据本地副本。分析范围是 Excel 行数上限内的前 1,048,575 条 CSV 记录，表头及前两行与工作簿核对；未逐行比对整个工作簿，也不推断完整 CFPB 数据库。官方页面称公开投诉数据可自由分析，但本地副本的下载时间与完整许可链未附凭证。[1]

观察单位：一条 Complaint ID 对应的公开投诉记录。模型输入仅为 Consumer complaint narrative；Product 为六类代理标签。公司回复等受理后字段及 Issue、Sub-issue 等相关结构化字段不进入推理。

表 1 核心字段字典与用途

字段	类型 / 含义	用途
Complaint ID	整数；投诉记录标识	去重排序与完整性检查，不作特征
Date received	日期；CFPB 收件日	按首次出现日期进行时间划分
Product	类别；消费者选择的产品	六类监督标签，含噪声
Consumer complaint narrative	自由文本；公开叙述	唯一预测特征；空值不入文本样本
Issue / Sub-issue	类别；消费者选择的问题	仅数据字典，不用于推理
Company response to consumer	类别；公司处理结果	受理后信息，禁止用作特征
State / ZIP code	地理字段，可能为空	仅偏差审计，不用于推理

样本质量与保留规则

16 列中叙述缺失 1,031,482 条（98.37%）；六类可用叙述 14,919 条。标准化文本完全重复的额外行 1,504 条，跨类别冲突组 1 个；这些组不进入建模。其中 9 条超过阶段一规则器 20,000 字符的输入限额。

六类文本中有 11,636 条含脱敏占位符，仍可能残留可识别信息；报告、日志及公开仓库只保存聚合统计与人工编写测试句，不保存原文。

关键字段缺失速览

字段	缺失条数	对本研究的影响
Consumer complaint narrative	1,031,482	决定文本样本的严重选择偏差
Complaint ID	2,390	全体记录不宜仅以 ID 去重
Product	121	不能映射六类标签
Issue / State	145 / 1,314	只做审计，不作模型输入

输入快照的 SHA-256：850d5d220285abecb4d4b94ae4c92a8f318476ce14bd0460c3d6361c79ae9694。校验值与数据卡片一致才运行正式实验。

3 探索性分析：可用性与时间变化

图 1 六类记录中含叙述的比例（%）



图 1 来源：本地前段数据的 Product 与叙述非空交叉统计；百分比为各产品内部覆盖率。征信占全部记录约 90.22%，但其叙述覆盖率只有约 0.10%，与其他类别差距巨大。

图 2 2026 年 3–5 月六类原始叙述量（条）

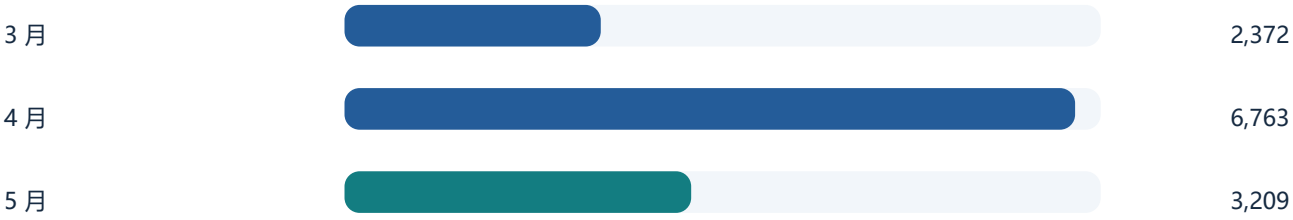


图 2 为去重前记录量；四月异常增高，不能把随机抽取记录视为独立、平稳的未来样本。具体成因不能仅凭这份副本确定。

观察如何改变设计

限定推断总体：只讨论已有公开叙述的六类投诉，不报告对全部投诉的准确率，也不以投诉量推断产品风险。[1]

征信为全部记录的 90.22%，却仅占所有非空叙述的 5.35%；这不是自然发生的类别平衡，而是公开叙述的选择机制所致。

先去重再按时间划分：跨月份存在完全相同的标准化文本。保留每组最早记录，冲突标签组剔除，使同一文本不跨训练、验证和测试；五月独立测试不用于参数选择。

报告类别性能：少数类与五月分布变化会使整体准确率失真，因此同时报告宏平均 F1 和六类召回率；置信区间揭示有限样本的波动。

4 清洗流水线与防泄漏实验设计

压缩 CSV 顺序读取前 1,048,575 条；校验 16 列及日期、产品、叙述字段；筛选六类且有非空文本的行。以 casefold 与空白归一化后的文本为键，跨全部月份分组：多标签冲突组剔除，其余选最早 Date received（再以 Complaint ID 打破并列）。只输出聚合统计，不导出原文或逐行文本哈希。

图 3 固定流水线

来源	筛选与分组	时间划分	训练与评价
CSV ZIP 前段 校验列与哈希	六类非空叙述 归一化文本去重	≤3 月训练 4 月验证 5 月测试	训练集拟合词表 验证集选 α 测试集只评一次

图 3 同一标准化文本先归为单组，再按组的首次日期分配；六月已在阶段一试运行查看，本阶段排除。

表 2 冻结划分及每类样本量

类别	训练 ≤3 月	验证 4 月	测试 5 月
债务催收	1465	1895	772
存取款账户	688	1396	649
信用卡	685	1360	665
转账 / 虚拟货币	305	729	249
按揭	255	512	241
征信	217	219	166
合计	3615	6111	2742

共排除阶段一已查看的六月样本 946 条。分割以固定日期界限定义，不使用测试标签调阈值。文本词袋、词表与条件概率只在训练集拟合；验证集只用于选 α。

可复现性与验证

脚本固定日期边界、词元规则、候选 α={0.1,1,5} 与自助重采样种子 42；输入以 SHA-256 标识。13 项自动测试覆盖缺列、空叙述、跨月重复、冲突标签、训练词表隔离、类别指标及边界条件。公开仓库含合成小样本供无原始数据时运行；真实数值需用户提供的同一快照。

验证项	运行结果
跨集合标准化文本哈希交集	0
词表仅在训练集拟合	3,615 条；6,881 个词
五月测试是否用于选择 α	否；只在四月验证集选择
运行环境与耗时	Python 3.12.14 标准库；全流程 23.7 秒

5 基线、指标与初步结果

比较三条路线：训练集多数类（不看文本）；阶段一固定关键词规则（可转人工）；训练集拟合词袋的多项式朴素贝叶斯（在四月验证集选平滑 α）。三者在同一五月测试集评估。主指标为六类宏平均 F1，使少数类与多数类等权；准确率反映总体错分，规则还报告自动覆盖率及自动处理正确率。

表 3 2026 年 5 月独立测试集结果

方法	准确率	宏平均 F1	宏 F1 95% 区间
训练多数类	28.2%	0.073	[0.070, 0.077]
固定规则	40.5%	0.482	[0.463, 0.500]
词袋朴素贝叶斯	74.2%	0.717	[0.697, 0.736]

区间为固定五月测试行的 500 次自助重采样分位数；朴素贝叶斯准确率 Wilson 95% 区间为 [72.5%, 75.8%]。该区间未覆盖时间漂移等系统误差。模型选择只看四月验证集，不再修改五月测试集。

固定规则自动覆盖率为 58.6%，仅对自动处理的样本计算正确率为 69.1%；表中整体准确率将转人工计为未正确分类。

表 4 五月测试集各类召回率

类别	训练多数类	固定规则	朴素贝叶斯
债务催收	100.0%	48.8%	74.7%
存取款账户	0.0%	30.0%	81.8%
信用卡	0.0%	35.9%	73.1%
转账 / 虚拟货币	0.0%	9.2%	41.4%
按揭	0.0%	66.0%	88.4%
征信	0.0%	71.1%	74.7%

朴素贝叶斯在转账 / 虚拟货币类仅召回 41.4%，明显低于按揭类的 88.4%；后续需针对相似产品词汇与少数类做错误分析，而不能仅凭总分宣布可部署。

将规则的转人工视为未正确分类来算总体召回与宏平均 F1，避免只在自动处理样本上报告准确率。误路由可能延误受理；部署时需以验证集设定拒答策略，再报告覆盖率—错误率权衡。

验证集选出的朴素贝叶斯平滑参数 α = 1.0。本阶段结果属于离线历史样本，不代表真实部署表现；下一阶段需比较 TF-IDF 线性模型并做近重复及时间漂移检查。

表 5 四月验证集的 α 选择记录

验证集 α	准确率	宏平均 F1
0.1	74.4%	0.716
1.0	74.8%	0.717
5.0	69.6%	0.535

α 先按宏平均 F1 最大选择；若相同，再比较准确率与较小 α。五月测试集只用于最终描述，未参与本次选择。

6 风险、后续计划与责任

6.1 数据与伦理风险

选择与测量偏差：叙述公开与否高度依赖产品类别；Product 是自报标签，不等于专家验证。CFPB 说明其数据库不是消费者经历的统计代表样本。[1][2]

时间适用性：CFPB 于 2026-08-14 宣布停止酌情发布投诉叙述。[3] 本研究只处理用户提供的历史快照，不能假定未来可持续获得同结构的新叙述。四月样本激增也需在阶段三做漂移分析。

隐私与错误后果：公开叙述的脱敏占位符不保证完全无个人信息；不发布原文。错分可能延误人工处理，系统应显示建议与原因，支持人工改派和审计，不用于判断事实、违法或赔偿。

主要风险	本阶段证据	缓解与边界
样本选择	总体叙述仅 1.63%；征信类覆盖率约 0.10%	只评价有文本的六类历史投诉
时间变化	四月六类原始叙述 6,763 条，高于三月 2,372 条	固定时间测试；阶段三做漂移审计
误分流	五月转账类召回率仅 41.4%	保留转人工与人工改派路径
潜在隐私	11,663 条六类叙述含脱敏占位符	公开仓库只放聚合与合成数据

6.2 阶段三至五的可验收计划

阶段 / 拟负责人	依赖与交付完成标准
阶段三 杨俊炜：建模评估 赵煜凡：数据采集	以阶段二冻结切分为依赖；比较 NB、TF-IDF 线性模型与规则，给出同集宏 F1、各类召回、错误类型和运行成本。
阶段四 杨俊炜：集成测试 赵煜凡：数据采集	在选定模型上实现本地 CLI：输入文本、类别或转人工输出；端到端测试覆盖空值、过长文本和异常路径。
阶段五 杨俊炜：审计修复 赵煜凡：数据采集	以阶段四系统为对象，验证集选拒答阈值；完成扰动、类别与时间漂移审计，形成回滚规则和整合报告。

每阶段保存输入哈希、运行环境、测试日志和独立 Git 标签；发布后的标签不移动。

6.3 贡献与 AI 使用声明

团队提供的分工：赵煜凡负责数据采集与提供本地历史快照；杨俊炜负责其余阶段二工作，包括问题修订、数据处理与分析、实验设计、基线实现、测试、图表、报告和仓库整理。阶段二代码、数据分析和报告草稿由 OpenAI Codex 协助生成；两位成员须理解、复核并按课程政策披露辅助范围。

参考资料

[1] CFPB, Consumer Complaint Database, 2026. consumerfinance.gov/data-research/consumer-complaints/。
[2] CFPB, How we share complaint data, 2026. consumerfinance.gov/complaint/data-use/。
[3] CFPB, The CFPB to Cease Discretionary Publication of Complaint Narratives and Visualizations, 2026-08-14. CFPB 公告。
本地资料：用户提供的 complaints.xlsx、complaints.csv.zip 与作业指导.pdf。数据字典和完整运行方式见仓库 DATA_CARD.md 与 README.md；原始文件不随仓库发布。