金融投诉文本的六类自动分流与人工复核系统

阶段二报告 | 数据与实验设计

项目	提交信息
课程 / 阶段	Python 与人工智能 / 阶段二
团队 / 成员	杨俊炜、赵煜凡
Git 仓库 URL / 提交标识	https://github.com/cwiapp/financial-complaint-routing phase-2-submission-v3（Git 标签）
日期	2026 年 11 月 4 日

执行摘要

本阶段将金融投诉文本分类限定为历史公开叙述中的六类产品分流。在工作簿对应的 1,048,575 条记录中，只有 17,093 条有叙述；六类共有 14,919 条。按标准化文本去重并先分组再按月份划分，训练、验证、测试集分别为 3,615、6,111、2,742 条。测试集上朴素贝叶斯宏平均 F1 为 0.717，与多数类和规则基线同集比较。主要局限是叙述选择偏差、标签噪声和历史数据时效；下一阶段将比较更强模型及错误成本。

1 修订问题与成功定义

决策任务：只根据首次受理时可获得的英文投诉叙述，建议六类产品路由；低置信或无效输入交人工复核。Product 是消费者选择的代理标签，不是经调查裁定的事实。系统不判断投诉真伪、违法性或赔偿。

评分标准响应：已收到阶段二六项评分标准，未收到阶段一逐条教师批注。本报告按六项标准组织证据：数据来源与字典、缺失与探索分析、处理与防泄漏、基线、评估及伦理复现。

成功标准：沿用阶段一预设的探索性门槛：宏平均 F1 ≥ 0.65、自动处理正确率 ≥ 0.85 且覆盖率 ≥ 0.50；并报告整体准确率和各类召回率。阈值不依据五月测试结果调整。

阶段一到阶段二的可核对变化

事项	阶段一	阶段二
数据使用	六月试运行片段	历史快照审计、跨月去重和固定三段划分
方法	多数类与固定规则	增加训练集拟合的词袋朴素贝叶斯
证据	单月原型检查	五月独立测试、类别召回率与 95% 区间

2 数据集文档与来源（15 分）

来源与收集过程：赵煜凡负责数据采集并向小组提供 complaints.csv.zip 与 complaints.xlsx 本地历史副本；本次由压缩 CSV 顺序读取前 1,048,575 条记录（Excel 最大数据行数），核对两份文件的表头及前两行，并计算压缩包 SHA-256。未逐行核对整个工作簿，也不推断完整 CFPB 数据库。原始下载时间、下载筛选条件和当时的许可凭证未随文件提供，故本报告只确认本地副本；CFPB 当前公开页面称其发布的数据可自由使用与分析。[1]

总体与观察单位：本地前段记录的收件日期范围为 2014-07-15 至 2026-07-05，共 16 列；一行为一条公开投诉记录，Complaint ID 是记录标识，但存在缺失。模型输入仅为 Consumer complaint narrative；Product 为六类代理标签。公司回复等受理后字段及 Issue、Sub-issue 等相关结构化字段不进入推理。

表 1 核心字段字典与用途

字段	类型 / 含义	用途
Complaint ID	整数；投诉记录标识	去重排序与完整性检查，不作特征
Date received	日期；CFPB 收件日	按首次出现日期进行时间划分
Product	类别；消费者选择的产品	六类监督标签，含噪声
Consumer complaint narrative	自由文本；公开叙述	唯一预测特征；空值不入文本样本
Issue / Sub-issue	类别；消费者选择的问题	仅数据字典，不用于推理
Company response to consumer	类别；公司处理结果	受理后信息，禁止用作特征
State / ZIP code	地理字段，可能为空	仅偏差审计，不用于推理

样本质量与保留规则

16 列中叙述缺失 1,031,482 条（98.37%）；六类可用叙述 14,919 条。标准化文本完全重复的额外行 1,504 条，跨类别冲突组 1 个；这些组不进入建模。其中 9 条超过阶段一规则器 20,000 字符的输入限额。

六类文本中有 11,636 条含脱敏占位符，仍可能残留可识别信息；报告、日志及公开仓库只保存聚合统计与人工编写测试句，不保存原文。

关键字段缺失速览

字段	缺失条数	对本研究的影响
Consumer complaint narrative	1,031,482	决定文本样本的严重选择偏差
Complaint ID	2,390	全体记录不宜仅以 ID 去重
Product	121	不能映射六类标签
Issue / State	145 / 1,314	只做审计，不作模型输入

输入快照的 SHA-256：850d5d220285abecb4d4b94ae4c92a8f318476ce14bd0460c3d6361c79ae9694。校验值与数据卡片一致才运行正式实验。

3 数据质量与探索性分析（20 分）

图 1 六类记录中含叙述的比例（%）

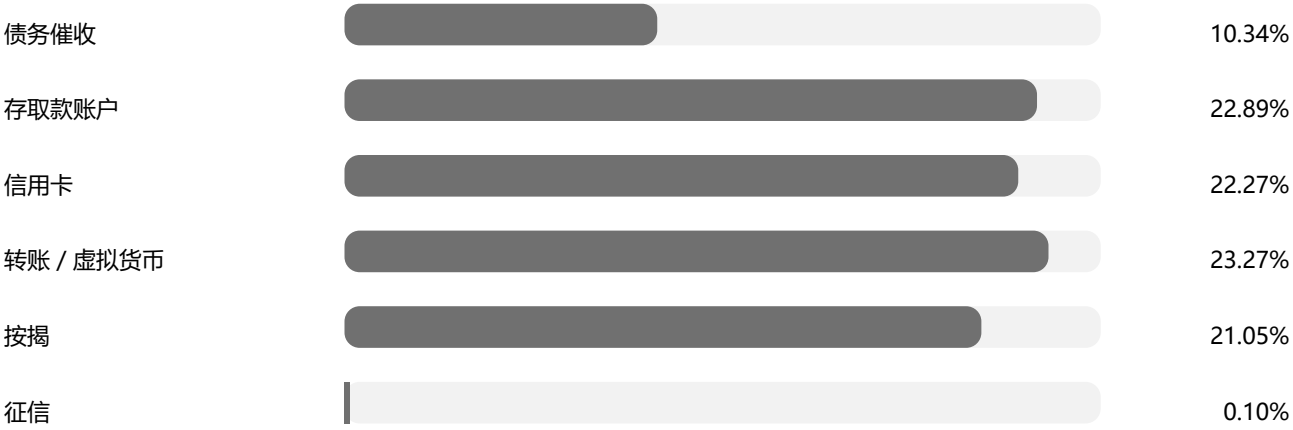


图 1 来源：本地前段数据的 Product 与叙述非空交叉统计；百分比为各产品内部覆盖率。征信占全部记录约 90.22%，但其叙述覆盖率只有约 0.10%，与其他类别差距巨大。

图 2 2026 年 3–5 月六类原始叙述量（条）

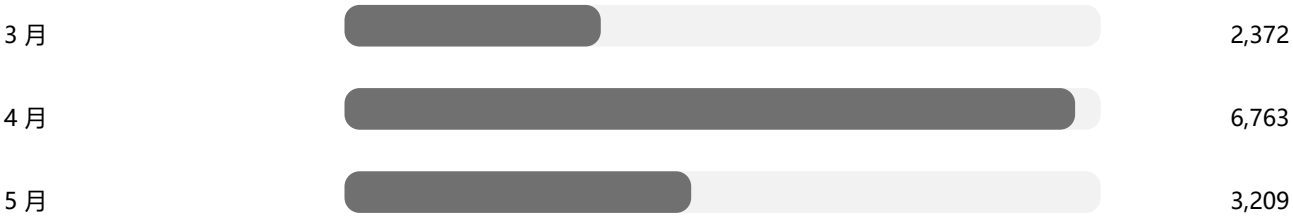


图 2 为去重前记录量；四月异常增高，不能把随机抽取记录视为独立、平稳的未来样本。具体成因不能仅凭这份副本确定。

观察如何改变设计

限定推断总体：仅评价有公开叙述的六类投诉；不把结果推广至全部投诉，也不据投诉量推断产品风险。[1]

征信为全部记录的 90.22%，却仅占所有非空叙述的 5.35%；这不是自然发生的类别平衡，而是公开叙述的选择机制所致。

先去重再按时间划分：跨月份存在完全相同的标准化文本。保留每组最早记录，冲突标签组剔除，使同一文本不跨训练、验证和测试；五月独立测试不用于参数选择。

类别分布随时间变化：去重后债务催收占训练、验证、测试集的 40.5%、31.0%、28.2%，信用卡则从 18.9% 升至 22.3%、24.3%。因此随机切分会掩盖未来月份的变化；评估仍须看宏平均 F1 和各类召回。

4 处理与防泄漏（20 分）

压缩 CSV 顺序读取前 1,048,575 条；校验 16 列及日期、产品、叙述字段；筛选六类且有非空文本的行。以 casefold 与空白归一化后的文本为键，跨全部月份分组：多标签冲突组剔除，其余选最早 Date received（再以 Complaint ID 打破并列）。只输出聚合统计，不导出原文或逐行文本哈希。

图 3 固定流水线

来源	筛选与分组	时间划分	训练与评价
CSV ZIP 前段 校验列与哈希	六类非空叙述 归一化文本去重	≤3 月训练 4 月验证 5 月测试	训练集拟合词表 验证集选 α 测试集只评一次

图 3 同一标准化文本先归为单组，再按组的首次日期分配；六月已在阶段一试运行查看，本阶段排除。

表 2 冻结划分及每类样本量

类别	训练 ≤3 月	验证 4 月	测试 5 月
债务催收	1465	1895	772
存取款账户	688	1396	649
信用卡	685	1360	665
转账 / 虚拟货币	305	729	249
按揭	255	512	241
征信	217	219	166
合计	3615	6111	2742

共排除阶段一已查看的六月样本 946 条。分割以固定日期界限定义，不使用测试标签调阈值。文本词袋、词表与条件概率只在训练集拟合；验证集只用于选 α。

可复现性与验证

脚本固定日期边界、词元规则、候选 α={0.1,1,5} 与自助重采样种子 42；输入以 SHA-256 标识。13 项自动测试覆盖缺列、空叙述、跨月重复、冲突标签、训练词表隔离、类别指标及边界条件。公开仓库含合成小样本供无原始数据时运行；真实数值需用户提供的同一快照。

验证项	运行结果
跨集合标准化文本哈希交集	0
词表仅在训练集拟合	3,615 条；6,881 个词
五月测试是否用于选择 α	否；只在四月验证集选择
运行环境与耗时	Python 3.12.14 标准库；全流程 23.7 秒

5 基线实现（15 分）与评估设计（20 分）

比较三条路线：训练集多数类（不看文本）；阶段一固定关键词规则（可转人工）；训练集拟合词袋的多项式朴素贝叶斯（在四月验证集选平滑 α）。三者在同一五月测试集评估。主指标为六类宏平均 F1，使少数类与多数类等权；准确率反映总体错分，规则还报告自动覆盖率及自动处理正确率。

表 3 2026 年 5 月独立测试集结果

方法	准确率	宏平均 F1	宏 F1 95% 区间
训练多数类	28.2%	0.073	[0.070, 0.077]
固定规则	40.5%	0.482	[0.463, 0.500]
词袋朴素贝叶斯	74.2%	0.717	[0.697, 0.736]

区间为固定五月测试行的 500 次自助重采样分位数；朴素贝叶斯准确率 Wilson 95% 区间为 [72.5%, 75.8%]。该区间未覆盖时间漂移等系统误差。模型选择只看四月验证集，不再修改五月测试集。

固定规则自动覆盖率为 58.6%，仅对自动处理的样本计算正确率为 69.1%；表中整体准确率将转人工计为未正确分类。

表 4 五月测试集各类召回率

类别	训练多数类	固定规则	朴素贝叶斯
债务催收	100.0%	48.8%	74.7%
存取款账户	0.0%	30.0%	81.8%
信用卡	0.0%	35.9%	73.1%
转账 / 虚拟货币	0.0%	9.2%	41.4%
按揭	0.0%	66.0%	88.4%
征信	0.0%	71.1%	74.7%

错误类型：朴素贝叶斯只识别出 249 条转账类中的 103 条（召回率 41.4%）；有 123 条被错分为存取款账户，是该类最大的误路由。单靠整体准确率无法发现这一风险。

门槛结论：朴素贝叶斯宏 F1 达到阶段一的 0.65 门槛，但全覆盖自动正确率仅 74.2%；规则覆盖率 58.6%、自动正确率 69.1%。两者均未达到 85% 的自动正确率目标，暂不能作为无人复核的自动分流。阶段三应在验证集选择拒答阈值，测试集报告覆盖率与错误率权衡。

验证集选出的朴素贝叶斯平滑参数 α = 1.0。本阶段结果属于离线历史样本，不代表真实部署表现；下一阶段需比较 TF-IDF 线性模型并做近重复及时间漂移检查。

表 5 四月验证集的 α 选择记录

验证集 α	准确率	宏平均 F1
0.1	74.4%	0.716
1.0	74.8%	0.717
5.0	69.6%	0.535

α 先按宏平均 F1 最大选择；若相同，再比较准确率与较小 α。五月测试集只用于最终描述，未参与本次选择。

6 伦理、写作与可复现性（10 分）

6.1 数据与伦理风险

选择与测量偏差：叙述公开与否高度依赖产品类别；Product 是自报标签，不等于专家验证。CFPB 说明其数据库不是消费者经历的统计代表样本。[1][2]

时间适用性：CFPB 于 2026-08-14 宣布停止酌情发布投诉叙述。[3] 本研究只处理用户提供的历史快照，不能假定未来可持续获得同结构的新叙述。四月样本激增也需在阶段三做漂移分析。

隐私与错误后果：公开叙述的脱敏占位符不保证完全无个人信息；不发布原文。错分可能延误人工处理，系统应显示建议与原因，支持人工改派和审计，不用于判断事实、违法或赔偿。

6.2 阶段三至五的可验收计划

阶段 / 拟负责人	依赖与交付完成标准
阶段三 杨俊炜：建模评估 赵煜凡：数据采集	以阶段二冻结切分为依赖；比较 NB、TF-IDF 线性模型与规则，给出同集宏 F1、各类召回、错误类型和运行成本。
阶段四 杨俊炜：集成测试 赵煜凡：数据采集	在选定模型上实现本地 CLI：输入文本、类别或转人工输出；端到端测试覆盖空值、过长文本和异常路径。
阶段五 杨俊炜：审计修复 赵煜凡：数据采集	以阶段四系统为对象，验证集选拒答阈值；完成扰动、类别与时间漂移审计，形成回滚规则和整合报告。

每阶段保存输入哈希、运行环境、测试日志和独立 Git 标签；发布后的标签不移动。

6.3 明确分工与 AI 使用声明

成员	阶段二负责事项	对应可核对产物
赵煜凡	数据采集；向小组提供 CFPB 投诉本地历史快照。	complaints.xlsx、complaints.csv.zip（原始文件不公开）
杨俊炜	研究问题修订；数据字典与质量分析；清洗、去重和防泄漏划分；基线、评估与测试；图表、报告及 Git 仓库整理。	DATA_CARD.md、stage2.py、test_stage2.py、results/、本报告与 README.md

上述为团队告知的责任分工。阶段二代码、数据分析和报告草稿由 OpenAI Codex 协助生成；成员应复核结果、理解署名工作，并按课程政策披露 AI 辅助范围。

参考资料

[1] CFPB, Consumer Complaint Database, 2026. consumerfinance.gov/data-research/consumer-complaints/。
[2] CFPB, How we share complaint data, 2026. consumerfinance.gov/complaint/data-use/。
[3] CFPB, The CFPB to Cease Discretionary Publication of Complaint Narratives and Visualizations, 2026-08-14. CFPB 公告。
本地资料：用户提供的 complaints.xlsx、complaints.csv.zip 与作业指导.pdf。数据字典和完整运行方式见仓库 DATA_CARD.md 与 README.md；原始文件不随仓库发布。