阶段二研究报告 / 杨俊炜、赵煜凡

六类金融投诉的文本分流

历史样本上的可学性、错分成本与人工复核

2026 年 11 月 8 日 | Python 与人工智能课程

仓库 https://github.com/cwiapp/financial-complaint-routing | 提交 phase-2-submission-v4

执行摘要

本阶段检验投诉叙述中的英文词元能否支持六类产品分流。从 1,048,575 条本地记录筛出六类非空叙述，按首次收件日期去重并划分训练、验证和测试集。在 2,742 条五月投诉上，朴素贝叶斯宏平均 F1 为 0.717，比固定规则高 0.236，但自动处理正确率为 74.2%，低于阶段一的 85% 门槛。公开叙述的覆盖率随产品变化，五月结果只用于回顾性分析。下一阶段将用四月验证集选择人工复核门槛，并用新封存样本核验。

0.717
宏平均 F1
朴素贝叶斯，五月历史测试

+0.236
相对规则的提升
配对 95% 区间 [0.212, 0.259]

74.2%
自动处理正确率
全覆盖运行，未达到 85% 门槛

1 分流决策与成功标准

使用者是受理环节的人工审核员。输入为一条投诉叙述，输出为六个产品队列之一，或交人工复核。监督标签取自投诉记录的 Product 字段，反映消费者当时的产品选择。实验只使用叙述，审核员保留改派权。

阶段一使用固定词表试跑六月数据。阶段二冻结历史时间窗，加入训练多数类和朴素贝叶斯，并把转人工纳入统计。目前掌握的反馈是阶段一成绩偏低，教师逐条评语未提供。修订记录见附录。

表 1 阶段一预先设定的三项门槛

指标	门槛	为何需要
六类宏平均 F1	≥ 0.65	六类等权，关注少数队列能否被识别。
自动处理正确率	≥ 85%	减少误路由引发的重复转派和受理延迟。
自动覆盖率	≥ 50%	同时计量转人工负荷，防止大量弃权抬高正确率。

02 / 研究样本

哪些投诉进入实验

以 CFPB 公开数据库的字段定义作对照，分析范围限于本地 CSV 前段。

来源与采集记录

赵煜凡负责收集并提供 complaints.xlsx 和 complaints.csv.zip 两份本地文件。研究从 ZIP 中按文件顺序读取与工作簿容量对应的 CSV 前段，核对两份文件的表头及前两行。这个前段按文件位置截取，未进行随机抽样。CFPB 运营消费者投诉数据库，公开页面说明其发布的数据可供使用和分析 [1]。本地文件的原始下载日期、筛选条件和当时许可凭证尚无记录，因此保留 ZIP 校验值和实际读取边界。

表 2 样本筛选台账

处理范围	条数	说明
CSV 前段	1,048,575	16 列，收件日期 2014-07-15 至 2026-07-05。
叙述非空	17,093	占读取记录的 1.63%，其余叙述为空。
属于六个目标产品且日期有效	14,919	非目标产品叙述 2,174 条。六类日期无效 0 条。
按首次出现去重后	13,415	清洗减少 1,504 条，规则见第 4 节。
进入训练、验证和测试	12,469	另有 946 条处于阶段一已查看的六月，排除。

表 3 核心字段字典

CSV 字段	含义及数据类型	缺失	实验角色
Consumer complaint narrative	公开投诉叙述，文本	1,031,482	唯一模型输入
Product	消费者选择的产品，类别	121	六类监督标签
Date received	CFPB 收件日期，日期	0	去重排序、时间切分
Complaint ID	投诉编号，标识符	2,390	同日同标签时排序
Issue	消费者选择的问题，类别	145	排除，避免依赖相关标注
Company response to consumer	企业处理结果，类别	222,634	排除，发生于受理之后
State	州，类别	1,314	仅供总体缺失审计

观察单位为一条投诉记录。编号缺失时仍按叙述内容识别重复。主要证据覆盖快照前段有公开叙述的六类投诉。未公开叙述、其他产品和未进入 CFPB 公开数据库的投诉没有评估。其余字段的定义和缺失统计见 仓库数据卡。

03 / 数据证据

谁的叙述可见，队列比例如何变化

同一快照中，叙述可见性随产品变化，产品构成也随月份变化。

图 1 各产品中公开叙述的可得率

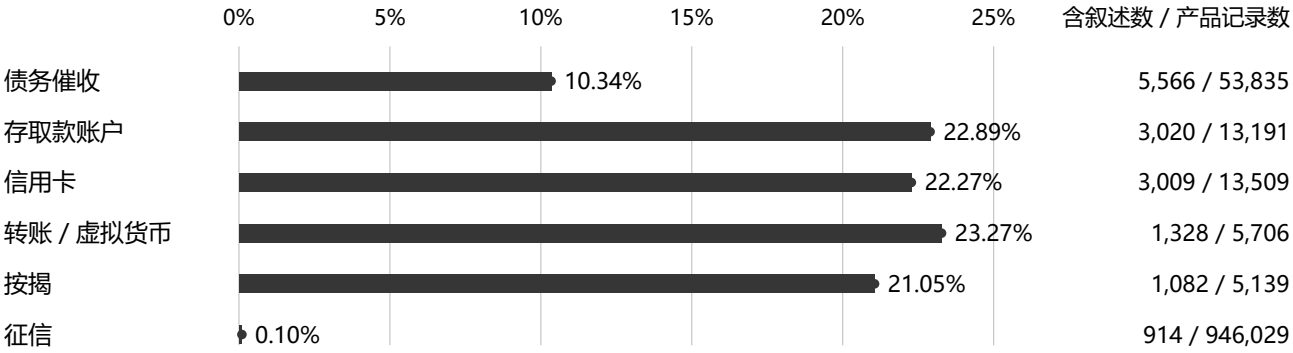


图 1 的分母是对应产品在 CSV 前段的全部记录。征信占前段全部记录的 90.22%，却只占六类非空叙述的 6.13%。因此模型成绩适用于有叙述的样本，空文本须进入人工队列。

图 2 去重后各时间段的类别构成

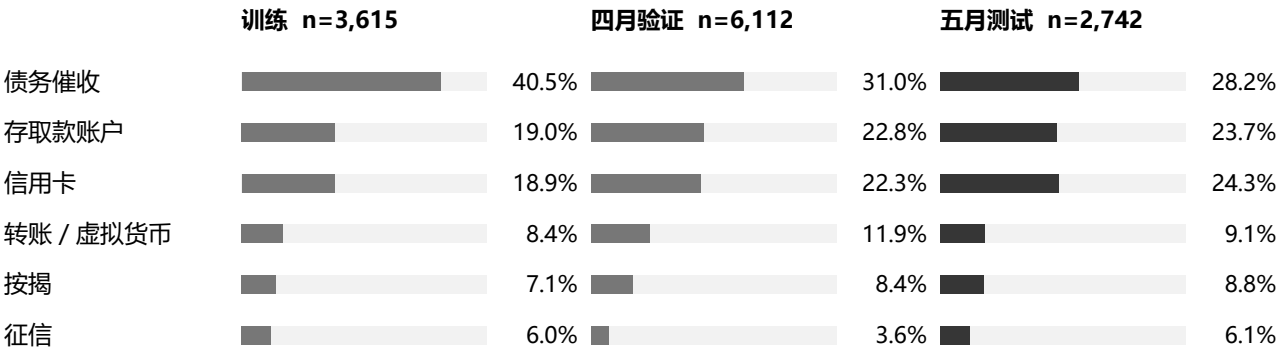


图 2 每列以该时间段的记录数为分母，条长的共同上限为 50%。债务催收占比从训练集的 40.5% 降至五月的 28.2%，信用卡从 18.9% 升至 24.3%。部署会遇到月份变化，因此用时间切分衡量这种变化下的表现，并保留逐类指标。

图 3 去重前六类叙述的长度分组（横轴为字符数，n = 14,919）

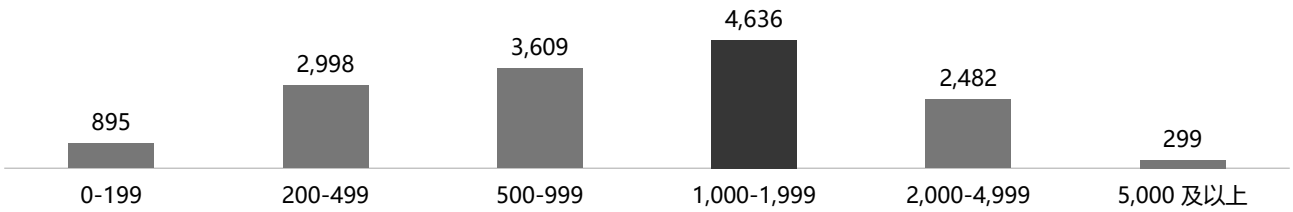


图 3 使用归一化后的文本。中位数为 991 字符，第 95 百分位为 3,484。其中 11,636 条含遮盖标记，9 条超过旧规则的 20,000 字符限制。朴素贝叶斯去除 x 遮盖词，每条最多保留 5,000 个英文词元。五月有 1 条超过这一上限。脚本未单独筛除非英语叙述。Product 由投诉者选择，混合产品叙述可能造成标注差异。

04 / 实验协议

先处理到件顺序，再冻结时间窗

同一标准化文本只能分到一个集合，词表和参数选择按时间隔离。

图 4 从历史 CSV 到评估结果

01 读入与检查	02 到件去重	03 固定时间窗	04 拟合与评价
校验 ZIP 哈希、字段和日期。筛选六类非空叙述。	大小写及空白归一化。按最早收件日决定保留与排除。	截至三月训练。四月验证。五月测试。	训练集拟合词袋。四月选平滑系数。汇总五月结果。

重复与冲突如何处理

对叙述按大小写与空白归一化后计算哈希。同一个哈希以最早收件日为准。同日标签一致时保留一条，最早同日出现多个产品标签时隔离该组。后续日期出现的重复文本不会进入其他集合，其标签不会追溯改变早期记录。流程见图 4。

六类候选中有 1,504 条超出每组一条的重复记录。最早同日标签冲突而排除 0 组。有 1 条较晚记录的标签不同，修订后保留了原来被删除的四月首条记录。三个集合之间的标准化文本哈希重叠为 0。近似改写及同一投诉者的多次投诉尚未识别。

表 4 时间窗、观察范围与用途

集合	实际日期范围	条数	用途
训练	2016-01-11 至 2026-03-31	3,615	拟合多数类与词袋模型
验证	2026-04-01 至 2026-04-30	6,112	以宏平均 F1 选择 α
历史测试	2026-05-01 至 2026-05-31	2,742	同批记录比较三个基线

特征、边界与运行验证

词袋使用英文词元计数，文档频次至少为 2。词表仅在 3,615 条训练记录上拟合，得到 6,881 个词元。四月和五月仅用训练词表转换。五月数据没有参与 α 的选择。旧规则词表沿用阶段一版本。

五月已用于前一版报告，因此本次采用相同月份作回顾性比较。下一阶段的模型和复核门槛仍用四月验证集探索，最终确认需要新的封存样本。阶段一已查看过的六月继续排除。

运行环境为 Python 3.12.14。重采样种子为 42。仓库保留数据检查、归一化、分割与基线的合成测试。执行命令见附录。

05 / 比较与不确定性

模型学到了分流信号

三个基线在同一批历史样本上比较，覆盖率和正确率同时报告。

多数类基线始终预测训练集中最多的债务催收，衡量类别先验能达到的分数。固定规则匹配阶段一的关键词，冲突或无命中时可转人工。多项式朴素贝叶斯使用训练词袋，为衡量文本词频能否改善分流而设。

表 5 2026 年 5 月历史测试结果（n = 2,742）

基线	总体正确率	宏 F1 / 95% 区间	自动覆盖率	自动正确率
训练多数类	28.2%	0.073 [0.070, 0.077]	100.0%	28.2%
阶段一固定规则	40.5%	0.482 [0.463, 0.500]	58.6%	69.1%
词袋朴素贝叶斯	74.2%	0.717 [0.697, 0.736]	100.0%	74.2%

宏平均 F1 是六个类别 F1 的等权平均。总体正确率以全部测试记录为分母，转人工计为未正确自动分流。自动正确率只用自动处理的记录作分母。两项指标并列，便于区分审核负荷与自动错分。

差值比两条单独区间更直接

在表 5 的同一批投诉上，朴素贝叶斯的宏平均 F1 比固定规则高 0.236。每次对五月记录有放回抽样，并用相同的样本索引重算两个模型，所得差值的 95% 区间为 [0.212, 0.259]。单模型宏 F1 也使用 500 次行级自助抽样。该区间描述当前样本的抽样波动，跨月份漂移另需验证。

表 6 只用四月验证集选择朴素贝叶斯平滑系数

候选 α	验证宏 F1	验证总体正确率	选择
0.1	0.7162	74.4%	—
1	0.7172	74.8%	选用
5	0.5346	69.6%	—

按验证宏 F1 选 α = 1。它和 α = 0.1 的差距约为 0.001，优势很小。

规则把 1,135 条交人工，其中无命中 1,011 条、命中冲突 118 条、超长 6 条。规则自动误路由 496 条，自动正确率的 Wilson 95% 区间为 [66.8%, 71.3%]。朴素贝叶斯全量自动分流，正确 2,034 条、误路由 708 条，自动正确率区间为 [72.5%, 75.8%]。朴素贝叶斯达到宏 F1 与覆盖率门槛，但增加了自动误路由的绝对数量。两种方法都未达到 85% 自动正确率门槛。

06 / 决策与交付

转账投诉最常被错分到存取款账户

保留人工复核，并把高风险队列作为下一轮验收的重点。

图 5 朴素贝叶斯的五月混淆矩阵（n = 2,742，单位为条）

实际类别		催收	账户	信用卡	转账	按揭	征信
债务催收	772	**577**	48	68	3	23	53
存取款账户	649	7	**531**	67	30	4	10
信用卡	665	33	99	**486**	14	8	25
转账 / 虚拟货币	249	0	**123**	22	**103**	0	1
按揭	241	4	12	9	1	**213**	2
征信	166	28	4	7	1	2	**124**

图 5 按行给出数据标签、按列给出预测标签。249 条转账类中，103 条进入正确队列，召回率 41.4%。其中 123 条被路由到存取款账户，占转账类的 49.4%。仅凭聚合矩阵无法判定具体文本中的原因。

风险如何改变验收

错分可能让正确队列迟收案件，错误接收的队列也要承担改派。用人工确认保留回退路径，在四月验证集上选择拒答门槛，记录各类召回率和人工负荷。将来用新封存样本同时核验表 1 三项目标。

投诉流程与发布条件造成样本选择偏差 [1][2]。本地副本无法逐条核验公开同意，叙述也可能残留个人信息。原文留在本地，公开的数据证据只含汇总和合成示例。CFPB 于 2026 年 8 月宣布停止酌情公开叙述 [3]。后续验收需要先取得合适的新样本。

表 7 下一阶段的交付与验收

阶段	负责人及依赖	验收证据
3 方法比较	杨俊炜建模。赵煜凡核查后续数据。	四月验证集比较线性模型与现有基线，冻结门槛及新样本计划。
4 系统集成	杨俊炜实现。依赖已冻结的模型。	本地命令可完成队列建议和转人工，并通过空文本及超长文本检查。
5 复现与审计	杨俊炜审计。赵煜凡跟进数据来源。	以可用的新封存样本核验表 1，汇报转账召回、覆盖率和误路由。

成员分工

成员	责任及可核对产物
赵煜凡	数据采集，提供两份本地历史文件，并负责核对后续数据的来源信息。
杨俊炜	研究设计、数据审计、去重与时间划分、基线及评估、测试、图表、报告和仓库整理。对应 stage2.py、test_stage2.py、results、数据卡和本报告。

AI 使用披露。OpenAI Codex 协助修改代码、复核实验、生成图表和撰写报告。上表列的是团队责任分工。

A / 附录

参考资料与复现索引

参考资料、数据版本、执行命令和修订记录。

参考资料

[1] Consumer Financial Protection Bureau, “Consumer Complaint Database.” [Online]. https://www.consumerfinance.gov/data-research/consumer-complaints/

[2] Consumer Financial Protection Bureau, “How we share complaint data.” [Online]. https://www.consumerfinance.gov/complaint/data-use/

[3] Consumer Financial Protection Bureau, “The CFPB to Cease Discretionary Publication of Complaint Narratives and Visualizations,” Aug. 14, 2026. [Online]. CFPB 公告

复现步骤

解压仓库或检出提交标签。合成测试可直接执行。真实结果需要取得同一历史 ZIP 并按下列命令指定路径，官方当前导出文件可能属于不同版本。仓库结果只含汇总值。

```
cd stage2
python -m unittest -v test_stage2.py
python stage2.py --data "本地路径/complaints.csv.zip" --output results/summary.json
python make_charts.py
python make_data_card.py
python -m pip install -r requirements.txt
python build_report.py
```

输入 ZIP 的 SHA-256

850d5d220285abecb4d4b94ae4c92a8f318476ce14bd0460c3d6361c79ae9694

校验对象为 ZIP 文件本身。PDF 的复建需要 ReportLab 和 Windows 微软雅黑字体。运行说明见 阶段二 README。

修订记录

阶段一之后补齐字段及来源记录、时间切分和简单学习基线。本次修订重新按到件顺序核对去重，加入同样本的配对区间和错误队列图，并把回顾性结果与下一轮独立验收分别标明。具体教师评语尚未提供。