金融投诉叙述文本的六类自动分流与人工复核系统

阶段一开题报告 | 问题定义与计算原型

项目	提交信息
课程 / 阶段	Python 与人工智能 / 阶段一
团队 / 成员	杨俊炜、赵煜凡
日期	2026 年 10 月 12 日

执行摘要

本项目面向金融投诉受理人员，研究如何仅根据英文投诉叙述，将案件初步分流至六个常见金融产品类别；无法可靠判断时交由人工复核。提供的工作簿有 1,048,575 条记录，但仅 17,093 条含公开叙述，其中六类目标共有 14,919 条。阶段一完成了数据流式核查、规则分流原型与 15 项自动化测试。以去重后的 2026 年 6 月 946 条六类样本作初步检查，规则自动覆盖 61.31%，被自动处理样本的准确率为 72.93%；这些数值不代表最终模型表现。后续将比较多数类、TF-IDF 线性模型与带拒答的系统，采用时间切分、错误分析和鲁棒性测试，限制系统用途为辅助分流。

1 问题定义与范围

问题：给定一条首次提交的英文投诉叙述，系统输出六个产品类别中的一个，或输出“需人工复核”；同时返回可检查的依据或拒答原因。目标用户是受理和分流人员，决策任务是辅助路由，而非判断投诉真伪、违法性、责任或赔偿。

输入：单条纯文本叙述（字符串）。输出：JSON：status=auto/review、product、reason、evidence。只用叙述作为预测特征；Product 是监督标签，Issue、Sub-issue、公司处理结果等字段不进入推理，以免发生信息泄漏。

范围：首期仅支持债务催收、存取款账户、信用卡、汇款 / 虚拟货币、按揭、征信六类；空文本、过短、过长、无规则匹配和并列命中均转人工。对其他产品及非英文投诉不作自动分类。

2 数据可行性与相关工作

2.1 本地数据审计

提供的 Excel 工作簿含 16 列、1,048,575 条数据，已达 Excel 单表行数上限；同目录压缩 CSV 可流式读取，原型只读取其前 1,048,575 条，并核对了工作簿行数和非空叙述数。下表是这段数据中的六类目标样本。

产品类别	总记录	有叙述	叙述覆盖率
债务催收	53,835	5,566	10.34%
存取款账户	13,191	3,020	22.89%
信用卡	13,509	3,009	22.27%
汇款 / 虚拟货币	5,706	1,328	23.27%
按揭	5,139	1,082	21.05%
征信	946,029	914	0.10%

表 1 六类产品的文本可用性。全部 1,048,575 条中仅 17,093 条（1.63%）有叙述；六类合计 14,919 条。征信占全部记录约 90.2%，但文本覆盖率极低，因此不能把文本模型评估推广到全部投诉。

来源与标签：本地文件为 complaints.xlsx 和 complaints.csv.zip；字段形式与 CFPB 投诉数据库一致，但原始下载日期和许可适用细节尚待团队核实。[1] 说明 Product 是投诉人识别的类别，故它是可用的代理标签，不等于经专家裁定的客观正确分类。

SHA-256（xlsx）：12CEDEB7B886B8DEA2DF2580A5FA05888ECA9DC61463FA4EF5F8222E14CF7455
SHA-256（CSV ZIP）：850D5D220285ABECB4D4B94AE4C92A8F318476CE14BD0460C3D6361C79AE9694

2.2 初步相关工作（非完整文献综述）

[1] CFPB 数据库提供投诉产品、议题、处理等结构化字段，并提醒公开投诉不是消费者经历的统计代表样本。本项目据此限定目标总体为“可获取叙述的六类投诉”。[2] TF-IDF 可将文本转成稀疏特征，适合后续与线性分类器组成可复现的学习基线。[3] 选择性分类研究提出以拒答率换取更低的自动处理错误率，启发本项目同时报告覆盖率与自动处理准确率。

项目差距：本项目不追求新算法；重点在明确输入时点、限制标签含义、处理文本缺失与重复、将分类和人工复核接成可运行流程，并用真实的时间切分和失败案例检验其可信度。

3 计算建模与 Python 原型

3.1 形式化表示

令 x 为英文叙述字符串，y 属于六类产品集合 Y。分类器 f(x) 给出候选类别，选择函数 g(x)∈{0,1} 决定是否自动分流；g(x)=0 时输出 review。阶段一以透明规则构造 f 和 g；后续将用训练数据学习 f，并仅在验证集上确定拒答阈值。

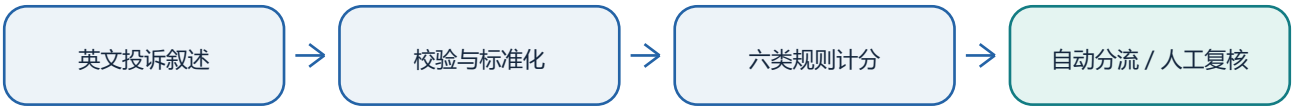


图 1 阶段一原型流程。数据审计独立于在线推理；推理端仅接收文本。

3.2 模块、假设与复杂度

函数	职责与边界
normalize / route	标准化空白与大小写；按六类关键词计分；并列、无匹配及无效长度转人工。规则命中词仅是线索，不是校准概率。
iter_workbook_segment / audit	从压缩 CSV 流式读取与 Excel 行数相同的前段，核对类别与文本覆盖率；不将整个 8.9 GB 原始 CSV 解压到磁盘。
evaluation_rows / score	以标准化叙述散列去重，剔除同一文本跨类别冲突组，给出多数类及规则的基本评价。

规则数固定时，单条推理时间约 O(L×K)，L 为文本长度、K 为关键词数；推理内存约 O(L)。数据审计单次顺序扫描 N 条记录，时间 O(N)、额外统计内存随类别数增长。评估需保存约 1.5 万条目标文本以跨月份去重，机器内存负担可控。

3.3 可复现演示与自动化测试

执行 python prototype.py demo --text "A debt collector keeps calling about a debt I do not owe."，输出 status=auto、product=Debt collection，并列出命中词。空文本、过短文本、过长文本、没有命中和并列命中均转人工。python -m unittest -v 已运行 15 项测试并全部通过，覆盖输入类型、归一化、词边界、六类中的代表性预测和空评估集。

阶段一原型是可运行的规则基线；下一阶段训练 TF-IDF 线性模型前，不把这些规则当作已校准的 AI 概率系统。

4 初步证据与后续评估方案

4.1 阶段一试运行

从六类叙述中按标准化文本去重、去除跨类冲突，再选取首次出现在 2026 年 6 月的 946 条作原型检查。多数类根据此前月份确定为“债务催收”。规则方法没有用该月样本训练；这仍是开发阶段的试运行，不作为后续最终测试集。

方法 / 指标	结果	解释
多数类：整体准确率	27.38%	所有样本均给出债务催收类别。
多数类：宏平均 F1	0.0716	反映六类不平衡下的差表现。
规则：自动覆盖率	61.31%	约四成转人工；312 条无命中，54 条并列。
规则：自动处理准确率	72.93%	仅在自动处理的样本上计算，不能与整体准确率直接等同。
规则：宏平均 F1	0.5042	将转人工视为未正确分类，在全部 946 条上计算。

表 2 初步规则基线。六月测试片段的征信类仅 18 条，类别指标不稳定；没有给出最终模型的泛化保证或显著性结论。

4.2 固定评估方案与成功标准

阶段二先冻结数据字典和去重规则：同一标准化叙述若跨类冲突则剔除；其余按首次出现日期归组，确保相同文本不跨集合。计划用 2026 年 4 月及以前作训练 / 内部验证，2026 年 5 月作独立最终测试；6 月的阶段一试运行样本不参与后续模型选择或正式成绩。仅在训练集拟合词表和 IDF。

主指标为六类宏平均 F1；同时报告每类召回率、混淆矩阵、覆盖率—自动处理准确率曲线及运行时延。目标是相对多数类和规则基线有稳定改进；预设探索性门槛为宏平均 F1≥0.65、自动处理准确率≥0.85 且覆盖率≥0.50，若未达到须解释失败原因而非修改测试集。正式报告将加入置信区间。

4.3 主要风险与约束

选择偏差：叙述仅覆盖 1.63%，征信文本覆盖率约 0.10%。标签噪声：Product 是投诉人选择，不等于专家结论。[1] 时间与格式漂移：公开文本的政策可能变化；CFPB 已于 2026 年 8 月停止在数据库中继续发布叙述，必须明确本项目只评估现有静态副本。[4] 误分流成本：错误路由可能延误处理，故保留人工复核和审计记录。

5 阶段计划、责任与参考资料

阶段	具体工作与可交付证据
阶段 2：数据与实验	固定划分与数据卡片；清洗及防泄漏脚本；多数类、规则、TF-IDF + 逻辑回归基线；缺失和类别偏差图。
阶段 3：模型比较	在同一划分上比较线性模型、字符 n-gram 或轻量预训练模型；给出重复运行、错误分类及运行成本。
阶段 4：集成系统	提供 CLI 或本地网页：文本输入、类别 / 转人工输出、日志与异常处理；端到端及集成测试。
阶段 5：扩展与审计	加入验证集确定的拒答阈值、置信度校准、扰动与分组评估、数据漂移与回滚计划；形成最终报告草案。

分工：成员为杨俊炜、赵煜凡，具体分工尚未提供。建议分配数据审计、模型与评估、系统集成、文档与演示四项职责；提交前必须填写各成员实际工作、仓库 URL 与 phase-1-submission 的真实 commit/tag。下一阶段完成标准：可重跑同一划分和基线表，并保留失败案例。

负责任 AI 与使用声明

原始叙述可能仍有隐私风险，示例使用人工编写文本，不在日志或报告中展示完整原文。模型只为人工分流提供建议；对拒答、错误分流保留人工纠正路径。不以类别预测推断投诉真伪、公司违法或消费者权益。报告初稿、原型与测试由 OpenAI Codex（GPT-6）辅助生成；数据统计和测试由本地脚本实际执行，团队提交前须逐项复核、理解并按课程政策披露。

参考资料（初步）

[1] Consumer Financial Protection Bureau, “Consumer Complaint Database” 与 “How we share complaint data,” 2026. consumerfinance.gov/data-research/consumer-complaints/；consumerfinance.gov/complaint/data-use/。

[2] scikit-learn, “TfidfVectorizer” 官方文档. scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html。

[3] Y. Geifman and R. El-Yaniv, “Selective Classification for Deep Neural Networks,” NeurIPS 2017. arxiv.org/abs/1705.08500。

[4] CFPB, “The CFPB to Cease Discretionary Publication of Complaint Narratives and Visualizations,” 2026-08-14. CFPB 官方公告。

本地数据：complaints.xlsx 与 complaints.csv.zip（用户提供；文件哈希见第 2 页）。课程要求：作业指导.pdf，第 1–4 页。